Stage de M1 2025
DER Sciences de l'Ingénierie Électrique et Numérique

Mixture of Experts in LLM

Statistical and Neural Predictors for MoE

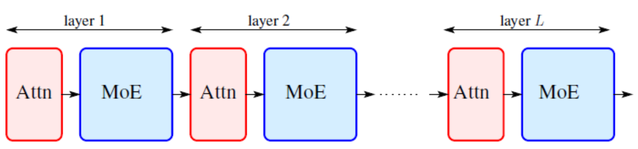
Pierre-Louis FILOCHE – International Laboratory on Learning Systems

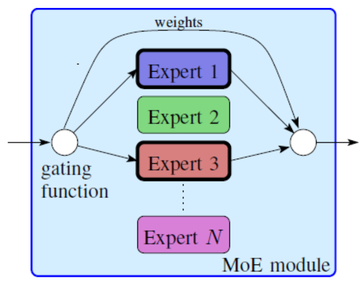
Introduction et Motivations

Les modèles de langage ne cessent de croître, augmentant fortement le coût d'inférence. Les *Mixture of Experts* (MoE) réduisent ce coût en n'activant qu'un sous-ensemble d'experts à chaque passage, ce qui apporte une parcimonie de calcul mais pas de mémoire. Tous les experts doivent rester accessibles, et les transferts limitent alors la performance en introduisant des latences importantes.

Architecture MoE

Chaque couche alterne attention et bloc MoE. La fonction de routage sélectionne dynamiquement *n* experts parmi *N*, dont les sorties sont combinées pour traiter le token.





Métriques de Précision

Chaque couche active 2 experts sur 8.
Top-1 : succès si l'expert le plus probable appartient à la vraie paire. **Top-2** : 0, 1 ou 2 bons experts parmi les deux prédits, normalisé par *2N (N* : nb de tokens).
Un prédicteur aléatoire atteint seulement **25 %** en top-2.

$$\text{Top-1} = \frac{1}{N}\sum_{\ell=1}^{N} \mathbf{1}\left[\hat{e}_\ell^{(1)} \in E_\ell\right],$$

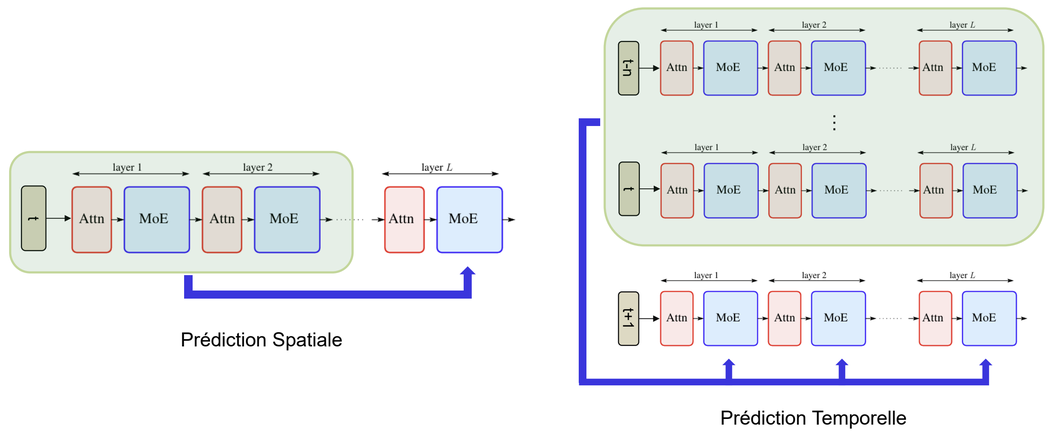
$$\text{Top-2} = \frac{1}{2N}\sum_{\ell=1}^{N} \left(\mathbf{1}\left[\hat{e}_\ell^{(1)} \in E_\ell\right] + \mathbf{1}\left[\hat{e}_\ell^{(2)} \in E_\ell\right]\right).$$

Prédicteurs automatiques

Des réseaux de neurones légers permettent d'aller au-delà des statistiques locales. Un perceptron multicouche (MLP) traite directement les identifiants de tokens, mais il reste limité. Un LSTM, conçu pour exploiter la dépendance entre tokens successifs, apprend à reconnaître les régularités de contexte et à anticiper les experts activés.

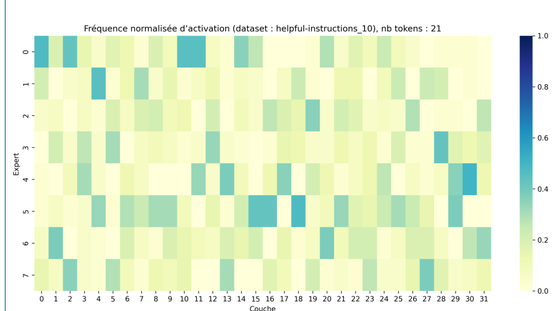
Prédictions

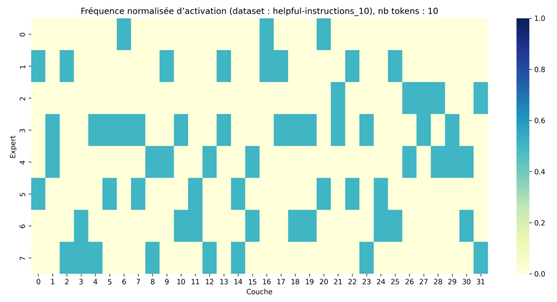
On souhaite avoir tous les experts sur GPU pour le calcul. Prédire les experts à l'avance permet de lancer leur chargement avant qu'il devienne bloquant et de masquer le coût des E/S.
La prédiction spatiale est précise mais tardive, tandis que la prédiction temporelle anticipe plus tôt avec plus d'incertitude ; leur combinaison réduit la latence d'inférence.



Résultats statistiques

Les prédicteurs statistiques exploitent les fréquences d'activation par token ou n-uplets. Le choix des experts n'est pas aléatoire : il dépend fortement du contexte du token. Certains token, comme le début de séquence suivent toujours la même trajectoire, alors que la ponctuation ou les mots ambigus activent des experts très variables.





Conclusions, perspectives

Le routage des experts est structuré et semble bien prédictible. Les statistiques révèlent des régularités utiles, mais les modèles séquentiels offrent une meilleure généralisation. La prochaine étape est d'affiner un réseau de neurones léger pour prédire les experts et d'intégrer ces prédictions dans une stratégie de préchargement asynchrone, afin de réduire la latence d'inférence.